

Perfil dos Contribuidores de Projetos de Código Aberto: Uma Análise de 1000 Projetos das Linguagens Mais Populares do GitHub

Arthur F. Costa¹, Fernando A. F. Ibrahim¹, Gabriel P. Carvalho¹, Luca F. Azalim¹,
Pedro H. B. de Castro¹, Renato M. A. Penna¹

¹Instituto de Ciências Exatas e Informática
Departamento de Engenharia de Software
Pontifícia Universidade Católica de Minas Gerais (PUC Minas)
Belo Horizonte – MG – Brasil

{arthur.costa¹, fafibrahim¹, gabriel.carvalho¹, lazalim¹,
pcastro¹, renato.matos¹}@sga.pucminas.br

Resumo. Este estudo investiga o perfil e o comportamento de desenvolvedores em projetos de software open source (OSS), analisando 1.000 repositórios das linguagens mais populares do GitHub. Por meio do paradigma Goal-Question-Metric (GQM), busca-se compreender como características dos contribuidores, como reputação, experiência e afiliação, impactam métricas de participação e engajamento. Os resultados indicam predominância de desenvolvedores dos Estados Unidos, Índia e China, com o Brasil em oitavo lugar. A maioria apresenta nível intermediário de experiência (88,41%), e apenas 3,74% são classificados como avançados. Contribuidores experientes alcançaram maior taxa média de aprovação de Pull Requests (83,76%) e ritmo mais constante de participação. Esses achados reforçam a influência da experiência na qualidade e regularidade das contribuições, contribuindo para o entendimento da dinâmica colaborativa em ecossistemas OSS. **Palavras-chave:** Software livre, GitHub, Experiência, Contribuidores, Engenharia de Software Empírica.

Abstract. This study investigates the profile and behavior of developers in open-source software (OSS) projects by analyzing 1,000 repositories from the most popular programming languages on GitHub. Using the Goal-Question-Metric (GQM) paradigm, it seeks to understand how contributor characteristics—such as reputation, experience, and affiliation—affect participation and engagement metrics. The results indicate a predominance of developers from the United States, India, and China, with Brazil ranking eighth. Most contributors show an intermediate experience level (88.41%), while only 3.74% are classified as advanced. Experienced contributors achieved a higher average pull request (PR) approval rate (83.76%) and a more consistent participation rhythm. These findings highlight the influence of experience on the quality and regularity of contributions, providing insights into the collaborative dynamics of OSS ecosystems. **Keywords:** Free Software, GitHub, Experience, Collaborators, Empirical Software Engineering.

1. Introdução

O desenvolvimento de software tem se transformado em uma atividade cada vez mais coletiva, apoiada por plataformas online que possibilitam a colaboração e a troca de conhecimento entre desenvolvedores. Entre essas plataformas, destaca-se o GitHub, um ambiente de hospedagem de código-fonte e controle de versão baseado em Git que permite o trabalho conjunto em projetos distribuídos, promovendo transparência, revisão contínua e construção coletiva do conhecimento técnico.

Os sistemas de software *open source* (OSS) ganharam relevância não apenas pela flexibilidade tecnológica que oferecem, mas também pela força de suas comunidades. O sucesso desses projetos depende fortemente da colaboração entre desenvolvedores distribuídos geograficamente, com diferentes níveis de experiência e motivações diversas. Nesse contexto, aspectos técnicos e sociais exercem influência direta sobre a qualidade das contribuições e sobre a aceitação das mudanças propostas nos repositórios.

A investigação de como e por quem as contribuições são realizadas em projetos *open source* tem se mostrado fundamental. Processos como a revisão de código são centrais para garantir a qualidade do software, mas podem ser afetados por fatores externos, como reputação, experiência prévia, gênero, afiliação institucional e localização geográfica dos contribuidores. Estudos recentes indicam que fatores sociais e técnicos, como reputação, experiência prévia, gênero, afiliação institucional e localização geográfica, podem influenciar significativamente a taxa de aceitação de *pull requests* (PRs) e a percepção de confiança nas comunidades OSS (Dey e Mockus 2020).

Compreender tais dinâmicas é essencial para promover ecossistemas mais inclusivos, transparentes e eficientes. Além de contribuir para o avanço do conhecimento científico sobre a colaboração em larga escala, a análise do perfil dos contribuidores pode orientar práticas mais equitativas de gestão e engajamento comunitário.

Neste contexto, o objetivo deste trabalho é caracterizar o perfil de contribuidores quanto à geolocalização, afiliação, experiência e engajamento, por meio de uma abordagem baseada no paradigma *Goal-Question-Metric* (GQM). Para isso, conduziu-se a análise de 52743 contribuidores dos 1000 repositórios mais populares do GitHub, a fim de responder às seguintes questões de pesquisa:

- Q1: Qual é a distribuição geográfica dos contribuidores de projetos OSS do GitHub pelo mundo?
- Q2: Qual é a afiliação profissional ou acadêmica dos contribuidores de projetos OSS no GitHub, e qual é o grau de dominância das empresas do grupo MANGA?
- Q3: Qual é o perfil de experiência dos contribuidores de projetos OSS no GitHub?
- Q4: Qual é o impacto da experiência dos contribuidores na taxa pessoal de aprovação das PRs em projetos OSS no GitHub?
- Q5: Qual a correlação da experiência dos contribuidores com a frequência de contribuição em projetos OSS no GitHub?

Esta introdução é seguida pela Seção 2, que apresenta os principais estudos correlatos. A Seção 3 descreve em detalhe a abordagem metodológica e o modelo analítico proposto. Os resultados experimentais e suas interpretações são discutidos na Seção 4, enquanto a Seção 5 examina as ameaças à validade. Por fim, a Seção 6 encerra o artigo com as conclusões.

2. Trabalhos relacionados

Diversos estudos têm investigado os fatores que influenciam a colaboração e a aceitação de contribuições em projetos de software de código aberto. Entre esses trabalhos, destacam-se pesquisas que abordam aspectos técnicos, sociais e demográficos dos contribuidores, bem como métricas de experiência e reputação dentro das comunidades de software *open source* (OSS).

O estudo de Rastogi et al. (2018) analisou a influência da localização geográfica na avaliação de *pull requests* (PRs) em projetos do GitHub. A pesquisa identificou diferenças estatisticamente significativas nas taxas de aceitação entre os 17 países mais ativos, observando que o resultado não se correlaciona diretamente com fatores como desenvolvimento econômico ou prevalência do inglês. No entanto, o estudo encontrou que PRs submetidas por desenvolvedores residentes no mesmo país do integrador têm maior probabilidade de serem aceitas, sugerindo um viés de co-localização na avaliação das contribuições. Esse trabalho se relaciona ao presente estudo por também investigar como a geolocalização dos contribuidores afeta a dinâmica de participação e aceitação em projetos OSS.

Outrossim, Bosu e Carver (2013) exploraram o papel da reputação e da rede social dos desenvolvedores no processo de revisão de código. Por meio da análise de repositórios do Gerrit, os autores demonstraram que contribuidores centrais na rede de colaboração têm maior probabilidade de ter suas contribuições aceitas, indicando que fatores sociais e de confiança exercem influência significativa na qualidade percebida do código. Esse trabalho é relevante por também examinar como indicadores sociais e de experiência moldam a aceitação e o engajamento dentro das comunidades de software livre.

Em consonância, Dey e Mockus (2020) propuseram uma análise quantitativa sobre os efeitos de fatores técnicos e sociais na qualidade das contribuições para o ecossistema NPM. Os autores demonstraram que a qualidade das PRs é fortemente influenciada pela experiência anterior do desenvolvedor e pela complexidade técnica do projeto. Esse estudo contribui para a discussão do presente trabalho ao evidenciar a importância da experiência acumulada como fator determinante no sucesso das contribuições em OSS.

No que se refere à caracterização da experiência dos desenvolvedores, Tamburri et al. (2019) destacam a relevância de modelos capazes de mensurar quantitativamente o conhecimento e a especialização dos contribuidores em ecossistemas colaborativos. O estudo propõe métricas baseadas em tempo de participação, diversidade de repositórios e volume de contribuições, reforçando a ideia de que a expertise pode ser inferida a partir de comportamentos observáveis nos repositórios. Essa perspectiva fundamenta a proposta do *Experience Score* (ES) adotado neste trabalho, que busca consolidar diferentes dimensões da atividade dos desenvolvedores em uma métrica única e interpretável. O ES se baseia em quatro fatores principais — Tempo de Atividade (T), Frequência de Contribuição (F), Volume de Contribuições (V) e Diversidade (D) — com pesos definidos de acordo com sua relevância empírica, sendo a frequência o componente de maior influência (0,45). A formulação do ES é inspirada em trabalhos anteriores que quantificaram a expertise por meio de evidências de atividade histórica, como os *“Experience Atoms”* propostos por Mockus e Herbsleb (2002) e as métricas de processo de Perez et al. (2021), além de manter coerência com abordagens mais recentes, como o *skill space* de Dey et al. (2020), que modela habilidades a partir das interações dos desenvolvedores com APIs e projetos.

Por fim, Lin et al. (2017) analisaram a rotatividade de desenvolvedores em projetos OSS e identificaram fatores que aumentam a probabilidade de desenvolvedores permanecerem ativos (*long-term contributors*), como começar a contribuir cedo e focar na modificação do código existente. Essa perspectiva fundamenta a inclusão da frequência e da diversidade de atividades no ES deste trabalho, abordando o engajamento como componente essencial para compreender a dinâmica das contribuições e a experiência dos desenvolvedores.

3. Metodologia

A metodologia adotada neste estudo consiste em um pipeline estruturado que organiza a coleta de dados, a limpeza, o cálculo, a sumarização e a análise das informações, conforme ilustrado na Figura 1.




Figura 1. Representação da metodologia adotada.

3.1. Seleção dos repositórios e período de análise

A seleção dos repositórios seguiu uma metodologia sistemática baseada em dois critérios principais: diversidade de linguagens de programação e popularidade dos projetos. A plataforma GitHub foi escolhida como fonte de dados por ser amplamente reconhecida como o repositório mais popular para código aberto (*open source code*), sendo vista como um recurso para encontrar software de qualidade [Lima et al., 2014].

Com o intuito de garantir a generalidade e a representatividade dos resultados, foram consideradas as **dez linguagens de programação mais populares** do GitHub em 2024 — *JavaScript, Python, Java, TypeScript, C#, C++, PHP, Shell, C e Ruby*.

Para cada linguagem, foram coletados os **100 repositórios com maior número de estrelas** (*stargazerCount*), totalizando uma amostra de **1.000 repositórios**. A métrica de estrelas foi adotada por representar um indicador consolidado de popularidade

e engajamento da comunidade, refletindo projetos amplamente utilizados e com ecossistemas ativos de contribuidores.

O período de análise abrangeu os últimos 12 meses de atividade nos repositórios selecionados, considerando também o histórico completo de cada contribuidor disponível por meio da *GitHub REST* e *GraphQL API*. Essa abordagem possibilitou uma visão longitudinal da evolução das contribuições e da consistência de engajamento dos desenvolvedores.

3.1.1. Caracterização da Amostra Coletada

A execução da metodologia nos 1000 repositórios resultou na identificação de **52.743 contribuidores únicos**, demonstrando a amplitude e diversidade da comunidade OSS analisada. Conforme apresentado na **Figura 2**, a distribuição geográfica desses contribuidores revela concentração significativa em regiões tecnologicamente desenvolvidas, com destaque para Estados Unidos (37,68%), Índia (26,09%) e Reino Unido (10,14%). O **mapa de calor geográfico** (Figura 2) ilustra visualmente essa distribuição, evidenciando os principais polos de contribuição ao ecossistema *open source*.




Figura 2. Distribuição geográfica dos 52.743 contribuidores analisados e mapa de calor por país.

Dos 52.743 contribuidores identificados, **25.536 tiveram localização geográfica determinada** (48,41% de cobertura), distribuídos em 19 países. Além da localização, foram coletados dados de afiliação profissional para 16.902 contribuidores (32,04%), permitindo análise detalhada do vínculo institucional dos desenvolvedores OSS.

Durante o período de 12 meses analisado, foram coletadas **10.014.005 Pull Requests (PRs)** e **3.814.799 issues**, representando uma base robusta e consistente para análise de perfis, padrões de contribuição e histórico de engajamento. Esse volume expressivo de dados possibilita inferências estatisticamente significativas sobre o comportamento colaborativo em projetos de código aberto.

3.2. Descrição do processo metodológico

As principais etapas do pipeline são:

1. Coleta de metadados básicos dos 1000 repositórios.
2. Coleta de dados de perfil (nome de usuário, empresa, localização e e-mail público) dos contribuidores ativos nos últimos 12 meses.
3. Coleta de dados históricos do total de *Pull Requests* (PRs) por mês e do total de *issues* por mês desde a criação da conta de cada contribuidor (por amostragem).
4. Coleta de dados sobre o estado, a data de criação, o autor e a lista de revisores de todas as PRs criadas nos últimos 12 meses.
5. Coleta de dados sobre a data de criação, estado (aberto ou fechado) e autor de todos os *issues* criados nos últimos 12 meses.
6. Execução do algoritmo de geolocalização dos contribuidores, utilizando os campos de localização e endereço de e-mail público.
7. Execução dos algoritmos de sumarização e correlação dos dados coletados para geração das métricas estabelecidas no *Goal, Questions, Metrics* (GQM).
8. Elaboração de gráficos e outras visualizações para responder às questões de pesquisa.

A execução da metodologia nos 1000 repositórios resultou na identificação de **52.743** contribuidores, com a coleta de **10.014.005** PRs e **3.814.799** *issues*, representando uma base consistente para análise de perfis e histórico de contribuição.

3.3. Como cada pergunta proposta será respondida

A pesquisa combina abordagens descritivas e correlacionais para responder às cinco questões de pesquisa, de Q1 a Q5. As etapas e métricas utilizadas para cada questão estão resumidas a seguir:

- Q1 - Distribuição Geográfica: Caracterização do cenário com pesquisa descritiva. A resposta é obtida após a Etapa 6, que executa o algoritmo de geolocalização dos contribuidores.
 - Métrica principal: número absoluto de contribuidores por país.
- Q2 - Afiliação e Dominância MANGA: Caracterização da afiliação por meio dos dados de perfil coletados (Etapa 2) e análise de frequência das empresas, incluindo o grupo MANGA (Meta, Amazon, Netflix, Google e Apple).
 - Métricas principais: número absoluto por empresa e número de contribuidores do grupo MANGA.
- Q3 - Perfil de Experiência: Quantificação da experiência por meio do *Experience Score* (ES), uma métrica composta. O cálculo é feito na Etapa 7, utilizando dados históricos da Etapa 3.
 - Métrica principal: *Experience Score* (ES) e sua categorização (Inicial, Intermediária, Avançada).
- Q4 - Experiência versus Taxa de Aprovação de PRs: Pesquisa correlacional quantitativa. Obtido a partir dos resultados da Etapa 7, através da correlação entre os níveis de ES e a taxa média de aprovação de PRs.
 - Métrica principal: taxa média de aprovação das PRs criadas por contribuidores em cada nível de experiência.

- Q5 - Experiência versus Frequência de Contribuição: Pesquisa correlacional quantitativa. Produzido a partir da Etapa 7, correlacionando o nível de ES com a frequência de contribuição (tempo médio entre cada PR).
 - Métrica principal: tempo médio entre cada PR criada por contribuidor.

3.4. Definição de hipóteses

As questões Q1, Q2 e Q3 são de natureza descritiva e de caracterização, focando em descrever fenômenos, populações e experiências. Para essas questões, a formulação de hipóteses formais não é necessária, pois o objetivo central é a caracterização do cenário [Creswell 2010, Wazlawick 2014]. Em contrapartida, para as questões Q4 e Q5, que buscam estudar a influência de fatores (experiência) na ocorrência de fenômenos (aceitação e frequência), enquadrando-se em pesquisa explicativa [Creswell 2010, Wazlawick 2014], são formuladas as seguintes hipóteses:

- Q4: *Como a experiência dos contribuidores afeta a taxa pessoal de aprovação das Pull Requests em projetos OSS no GitHub?*
 - *H0*: Não existe diferença estatisticamente significativa na taxa média de aprovação de PRs entre os diferentes níveis de experiência (Inicial, Intermediária e Avançada), medida pelo *Experience Score*.
 - *HA*: Há uma correlação positiva e estatisticamente significativa entre o nível de experiência dos contribuidores e a taxa média de aprovação de PRs, indicando que o aumento da experiência está associado a uma maior probabilidade de aceitação de suas contribuições.
- Q5: *Como a experiência dos contribuidores está correlacionada à frequência de contribuição em projetos OSS no GitHub?*
 - *H0*: Não há correlação estatisticamente significativa entre o nível de experiência dos contribuidores (*Experience Score*) e a frequência de contribuição (tempo médio entre PRs).
 - *HA*: Há uma correlação estatisticamente significativa entre o nível de experiência dos contribuidores e a frequência de contribuição, esperando-se que contribuidores mais experientes apresentem um ritmo mais constante e engajado de atividade.

3.5. Variáveis dependentes e independentes

A pesquisa se configura como um estudo empírico de larga escala, de natureza quantitativa e correlacional. A definição clara das variáveis é essencial para garantir a rastreabilidade entre as questões de pesquisa e as métricas utilizadas. As variáveis independentes representam os fatores explicativos relacionados ao perfil dos desenvolvedores, enquanto as variáveis dependentes correspondem aos indicadores de desempenho e engajamento observáveis. Essa distinção permite investigar de que forma características individuais influenciam o sucesso e a regularidade das contribuições em projetos OSS.

Tabela 1. Resumo das variáveis do estudo

Tipo de variável	Descrição
Variáveis independentes	
Geolocalização	País estimado de residência do contribuidor, obtido a partir do campo <code>location</code> do perfil público no GitHub e processado via <i>OpenStreetMap API</i> para normalização geográfica.
Afiliação	Empresa ou instituição à qual o contribuidor está vinculado e se pertence ao grupo MANGA (Meta, Amazon, Netflix, Google e Apple).
Experiência (Variável Central)	<i>Experience Score</i> (ES), classificado nos níveis: Inicial (0,1–0,35), Intermediária (0,35–0,65) e Avançada (acima de 0,66).
Variáveis dependentes	
Taxa média de aprovação de PRs	Percentual de <i>Pull Requests</i> criadas por um contribuidor que foram aceitas (<i>merged</i>) pelo repositório.
Frequência de contribuição	Tempo médio em dias entre cada PR criada por cada contribuidor.

3.6. Coleta de dados:

A coleta de dados foi conduzida por meio da *GitHub REST API* e da *GraphQL API*, utilizadas para extrair metadados dos repositórios e perfis de usuários. Foram obtidas informações referentes aos contribuidores ativos nos últimos 12 meses, incluindo nome de usuário, empresa, localização e endereço de e-mail público. Além disso, foram coletados dados históricos de atividade, como o total de *Pull Requests* (PRs) e *issues* criadas por mês desde a criação de cada conta, utilizados posteriormente para o cálculo das dimensões de experiência. Também foram obtidos detalhes sobre o estado (*merged*, *closed*, *open*), datas de criação, autores e revisores de todas as PRs e *issues* no período analisado.

A localização geográfica dos contribuidores foi determinada pela execução de um algoritmo que realiza consultas à *OpenStreetMap API*, permitindo mapear o país de residência e identificar se o desenvolvedor se encontra no mesmo país do integrador principal do projeto.

O nível de experiência, por sua vez, foi mensurado a partir do *Experience Score* (ES), uma métrica composta que parte da premissa de que a atividade observável pode servir como *proxy* para a proficiência técnica (Mockus e Herbsleb, 2002). O ES combina quatro dimensões — Tempo de Atividade (T), Frequência de Contribuição (F), Volume de Contribuições (V) e Diversidade (D) — sendo a frequência (F) a dimensão com maior peso (0,45), fundamentada em estudos que associam constância de atividade à expertise (Montandon, Silva e Valente, 2019).

A métrica é definida pela seguinte fórmula:

$$ES = 0.20T + 0.45F + 0.20V + 0.15D$$

Equação 1 – Experience Score

Para garantir a comparabilidade entre os diferentes componentes do escore (Equação 1), cada métrica foi **normalizada no intervalo [0, 1]** antes da aplicação dos pesos definidos. A normalização foi realizada de forma min-max, considerando o valor mínimo e máximo observados em cada dimensão (Tempo, Frequência, Volume e Diversidade). Essa abordagem assegura que todas as variáveis contribuam proporcionalmente para o cálculo do ES, evitando distorções decorrentes de diferentes escalas de medição.

O escore resultante permite classificar o nível de experiência dos contribuidores com base em um valor numérico entre 0 e 1, calculado a partir de quatro métricas principais: tempo de atividade (T), frequência de contribuição (F), volume de contribuições (V) e diversidade (D). Para facilitar a interpretação dos resultados, o escore é categorizado em três faixas de referência, conforme apresentado na Tabela 2.

Tabela 2. Valores de referência para o Experience Score

Nível de experiência	Faixa de valores
Inicial	0,10 – 0,35
Intermediária	0,35 – 0,65
Avançada	Acima de 0,66

A análise dos dados foi estruturada em duas etapas principais. Primeiramente, executou-se um processo de sumarização e correlação, gerando arquivos no formato JSON para cada questão de pesquisa, contendo os resultados e métricas derivadas. Em seguida, foram aplicadas técnicas estatísticas com o objetivo de verificar as hipóteses propostas. Estudos semelhantes fazem uso de regressão logística (Rastogi et al., 2018) e de testes não paramétricos, como o teste de Mann–Whitney U, para dados que não seguem distribuição normal (Zhang et al., 2024). De forma análoga, este trabalho emprega métodos de correlação e inferência estatística apropriados para relacionar o nível categórico de experiência (ES) com as métricas de aceitação e frequência de contribuição, possibilitando a identificação de padrões e relações significativas entre as variáveis analisadas.

4. Resultados

A partir da execução da metodologia descrita na seção anterior, foram coletados e processados dados referentes à atividade de contribuidores em repositórios públicos do GitHub. Nesta seção, são apresentados os resultados obtidos e suas respectivas análises, organizados conforme as cinco questões de pesquisa.

4.1. Q1: Como os contribuidores de projetos OSS do GitHub estão distribuídos geograficamente pelo mundo?




Figura 3. Distribuição geográfica dos contribuidores de projetos OSS.




Figura 4. Mapa de calor dos contribuidores de projetos OSS.

A análise da distribuição geográfica dos contribuidores, ilustrada na Figura 3, identificou um total de 52.743 contribuidores, dos quais 25.536 tiveram a localização determinada, representando uma cobertura de 48,41%. Conforme a Figura 4 apresenta, foram reconhecidos 19 países, sendo os Estados Unidos (4.830 contribuidores), Índia (2.419) e China (2.322) os mais representativos. O Brasil ocupa a oitava posição, com 707 contribuidores. Esses resultados evidenciam uma predominância de participantes oriundos da América do Norte e da Ásia, refletindo a concentração global de polos tecnológicos e de comunidades OSS nessas regiões.

4.2. Q2: Qual é a afiliação profissional ou acadêmica dos contribuidores de projetos OSS no GitHub, e qual é o grau de dominância das empresas do grupo MANGA?




Figura 5. Empresas com maior número de contribuidores identificados.




Figura 6. Comparação entre empresas MANGA vs Outras.

Treemap com principais organizações por número de contribuidores




Figura 7. Treemap das empresas e organizações com maior número de contribuidores.

A Figura 5 apresenta as principais afiliações profissionais identificadas entre os 16.902 contribuidores (32,04%). As empresas com maior número de participantes são Microsoft (492), Google (300), GitHub (277) e Meta (184), seguidas por organizações como Red Hat, Amazon e IBM.

O **treemap de afiliações** (Figura 7) permite visualizar proporcionalmente a distribuição dos contribuidores entre empresas e organizações. Destaca-se a presença significativa de empresas de tecnologia consolidadas, bem como de organizações ligadas ao desenvolvimento *open source*, como Vercel, Datadog e Asana.

O grupo MANGA — formado por Meta, Amazon, Netflix, Google e Apple — representa 2,3% de todos os contribuidores analisados, conforme demonstrado na Figura 6, evidenciando uma presença relevante, mas não dominante, dentro do ecossistema OSS.

Esse resultado sugere que, embora empresas de grande porte mantenham forte participação institucional no desenvolvimento de software aberto, a comunidade OSS permanece amplamente descentralizada, sustentada por uma base diversificada de contribuidores independentes e organizações menores. Dessa forma, observa-se que o desenvolvimento colaborativo continua sendo impulsionado majoritariamente por esforços comunitários, e não apenas corporativos.

4.3. Q3: Qual é o perfil de experiência dos contribuidores de projetos OSS no GitHub?




Figura 8. Distribuição dos níveis de experiência dos contribuidores.



Figura 9. Gráfico mostrando a proporção de contribuidores por nível de experiência.




Figura 10. Heatmap com distribuição detalhada dos níveis de experiência.

O *Experience Score* (ES) foi calculado para 52.743 contribuidores, considerando pesos de 0,45 para regularidade, 0,20 para duração, 0,20 para volume e 0,15 para diversidade. A média do escore foi de 0,491, com mediana de 0,501. Representado na Figura 8,

a maioria pertence ao nível Intermediário (88,41%), seguida dos níveis Inicial (7,85%) e Avançado (3,74%).

Conforme visualizado na Figura 9, a **visualização em gráfico de pizza** permite identificar claramente a predominância do perfil intermediário (90,21% na amostra detalhada) na comunidade OSS analisada. O **heatmap de níveis de experiência** (Figura 10) complementa essa análise, apresentando numericamente a distribuição: 175 contribuidores intermediários, 12 iniciantes (6,19%) e 7 avançados (3,61%) na amostra visualizada detalhadamente.

Esses resultados indicam que a maior parte dos desenvolvedores OSS possui envolvimento consistente, porém ainda limitado em termos de amplitude e profundidade técnica, caracterizando um perfil predominantemente intermediário. Dessa maneira, pode-se inferir que o ecossistema OSS é composto, em sua maioria, por desenvolvedores com experiência prática consolidada, mas ainda em processo de especialização. Isso reforça a importância das comunidades OSS como espaços de aprendizado contínuo e de formação de novos especialistas.

4.4. Q4: Como a experiência dos contribuidores afeta a taxa pessoal de aprovação das PRs em projetos OSS no GitHub?




Figura 11. Taxa média de aprovação de PRs por nível de experiência.




Figura 12. Tendência de aprovação de PRs em função do Experience Score.




Figura 13. Gráfico de barras duplas mostrando volume de PRs e taxa de aprovação por nível.

Heatmap com resumo de PRs, aprovação e contribuidores por nível de experiência

experience_level		total_prs	approval_perce...	contributors_count
1.	Advanced	1.286	86	7
2.	Intermediate	564	50,35	175
3.	Initial	39	28,21	12

1 - 3 / 3 < >

Figura 14. Heatmap detalhado com resumo de PRs, aprovação e contribuidores por experiência.

Conforme ilustram as Figuras 11 e 12, o nível de experiência influencia diretamente a taxa de aprovação de PRs. Contribuidores do nível Avançado apresentaram taxa média de aceitação de 83,76%, enquanto os níveis Intermediário e Inicial registraram, respectivamente, 57,74% e 56,24%.

O gráfico de barras duplas (Figura 13) permite visualizar simultaneamente o volume total de PRs submetidas e a taxa percentual de aprovação para cada nível de

experiência, evidenciando que contribuidores avançados não apenas submetem mais PRs (1.286 PRs totais, com 86% de aprovação na amostra visualizada), mas também obtêm taxas de aceitação substancialmente superiores em comparação com os níveis Intermediário (564 PRs, 50,35% de aprovação) e Inicial (39 PRs, 28,21% de aprovação).

O **heatmap detalhado** (Figura 14) complementa essa análise, apresentando numericamente a relação entre os três níveis de experiência, o volume de PRs, as taxas de aprovação e o número de contribuidores em cada categoria.

Esses resultados evidenciam uma correlação positiva entre experiência e aceitação das contribuições, indicando que desenvolvedores mais experientes tendem a submeter PRs de maior qualidade e aderência às diretrizes dos projetos. Dessa forma, é possível rejeitar a hipótese nula (H_0) estabelecida para a Q4 e aceitar a hipótese alternativa (H_A), concluindo que há uma relação estatisticamente significativa entre o nível de experiência e a taxa de aprovação das PRs. A experiência acumulada atua, portanto, como fator determinante para o reconhecimento técnico e a confiabilidade dos contribuidores no processo de revisão de código.

4.5. Q5: Como a experiência dos contribuidores está correlacionada à frequência de contribuição em projetos OSS no GitHub?




Figura 15. Intervalo médio entre PRs por nível de experiência.




Figura 16. Gráfico de linhas mostrando média de PRs e intervalo entre contribuições.

Heatmap com resumo da relação entre experiência e frequência de contribuições

	experience_level	contributors_count ▾	total_prs_mean	avg_interval_mean_days
1.	Intermediate	175	3,22	11,88
2.	Initial	12	3,25	118,51
3.	Advanced	7	183,71	2,92

1 - 3 / 3 < >

Figura 17. Heatmap com resumo da relação entre experiência e frequência de contribuições.

Os resultados apresentados na Figura 15 demonstram que contribuidores do nível Avançado registraram média de 126,67 PRs por contribuidor, com intervalo médio de 4,14 dias entre submissões. Em contraste, os níveis Intermediário e Inicial apresentaram médias de 3,31 PRs (intervalo de 14,66 dias) e 3,65 PRs (intervalo de 104,33 dias), respectivamente.

O **gráfico de linhas** (Figura 16) permite visualizar claramente a tendência inversa entre o nível de experiência e o intervalo médio entre contribuições: quanto maior a experiência, menor o intervalo entre PRs e maior a frequência de participação. Os contribuidores avançados mantêm um ritmo quase diário de contribuições (183,71 PRs com intervalo de 2,92 dias na amostra detalhada), enquanto iniciantes apresentam intervalos superiores a três meses (118,51 dias).

O **heatmap detalhado** (Figura 17) complementa essa análise apresentando numericamente os três indicadores principais: número de contribuidores (175 intermediários, 12 iniciais, 7 avançados), média de PRs totais (3,22; 3,25; 183,71 respectivamente) e intervalo médio em dias entre contribuições (11,88; 118,51; 2,92) para cada nível de experiência.

Esses dados indicam uma correlação positiva entre o *Experience Score* e a frequência de contribuições, demonstrando que desenvolvedores mais experientes mantêm um ritmo mais constante e engajado de participação. Dessa forma, rejeita-se a hipótese nula (H_0) e confirma-se a hipótese alternativa (H_A) para a Q5, uma vez que o aumento da experiência está associado a maior constância e produtividade. Em conjunto com os resultados da Q4, este achado reforça a importância da regularidade e da prática contínua como elementos centrais para a consolidação da expertise em ecossistemas OSS.

5. Ameaças à validade

Por se tratar de uma pesquisa empírica, este estudo está sujeito a ameaças à validade que podem influenciar a confiabilidade dos resultados e limitar a generalização das conclusões, conforme descrito a seguir.

Medida de experiência e expertise — A métrica central deste estudo é o *Experience Score* (ES), construída a partir de variáveis observáveis como frequência, tempo, volume e diversidade de contribuições. Embora a experiência seja considerada uma condição necessária para a *expertise*, a medição dessa característica apenas por meio de dados de repositório pode ser incompleta. O ES não captura dimensões cognitivas

e interpessoais da *expertise*, como habilidades em design, comunicação ou trabalho colaborativo, concentrando-se apenas em aspectos mensuráveis de engajamento técnico.

Representação de contribuição — O estudo considera majoritariamente contribuições de código, como *commits* e *pull requests* (PRs). Entretanto, outras formas de colaboração — como abertura de *issues*, revisão de código e discussões técnicas — também constituem formas relevantes de engajamento que não foram contempladas na base de dados analisada.

Fatores não controlados — Elementos como a complexidade do código submetido, a disponibilidade dos revisores, o tipo de licença do projeto e a natureza do vínculo do contribuidor (pago ou voluntário) podem impactar a taxa de aprovação das PRs e o engajamento individual, sem terem sido diretamente mensurados.

Seleção de projetos e plataforma — O estudo abrangeu apenas repositórios públicos do GitHub, o que pode limitar a generalização dos achados. Projetos mantidos em outras plataformas ou utilizando diferentes práticas de colaboração (como listas de e-mail ou repositórios privados) podem apresentar dinâmicas distintas de participação e revisão.

Generalização limitada — Para alcançar conclusões amplamente generalizáveis sobre o ecossistema OSS como um todo, seria necessária uma *família de experimentos* que replicasse este estudo em diferentes contextos tecnológicos e organizacionais. Assim, os resultados aqui apresentados são mais confiáveis quando interpretados dentro do escopo analisado, que compreende os **1.000 repositórios públicos mais populares de 10 linguagens de programação do GitHub**, considerando a atividade de contribuidores registrada nos últimos 12 meses.

6. Conclusão

Este estudo investigou a relação entre a experiência acumulada de desenvolvedores e seus padrões de colaboração e sucesso em projetos de software *open source* (OSS) hospedados no GitHub. A partir de uma abordagem empírica quantitativa baseada na mineração de repositórios, foi proposto e aplicado o *Experience Score* (ES), uma métrica composta que quantifica a experiência de um contribuidor com base na ponderação de frequência, volume, tempo e diversidade de suas atividades.

Os resultados demonstram que o nível de experiência exerce influência significativa sobre o desempenho e a integração social dos contribuidores. Conforme evidenciado pelas visualizações apresentadas nas Seções 4.4 e 4.5, contribuidores classificados com ES elevado apresentaram taxas médias de aceitação de PRs superiores (83,76% versus 56–57% dos níveis inicial e intermediário), maior regularidade de participação (intervalo médio de 4,14 dias entre PRs) e um padrão de engajamento mais constante ao longo do tempo.

A análise geográfica (Seção 4.1) revelou concentração significativa em regiões tecnologicamente desenvolvidas, com Estados Unidos, Índia e Reino Unido representando mais de 70% dos contribuidores identificados. Quanto à afiliação profissional (Seção 4.2), embora empresas como Microsoft, Google e Meta apresentem participação expressiva, o grupo MANGA representa apenas 2,3% dos contribuidores, indicando que o ecossistema OSS mantém-se descentralizado e sustentado por esforços comunitários diversos.

O perfil de experiência (Seção 4.3) demonstrou predominância do nível intermediário (88,41%), sugerindo que o ecossistema OSS funciona como espaço de aprendizado contínuo e formação de especialistas.

Esses achados reforçam a hipótese de que a experiência e a reputação funcionam como mecanismos sociais e técnicos centrais no ecossistema OSS, impactando diretamente a dinâmica de colaboração, a produtividade e a eficiência dos processos de revisão de código. Em particular, observou-se que desenvolvedores mais experientes tendem a receber respostas mais rápidas, ter maior aceitação de suas contribuições e exercer papel de liderança técnica nos projetos.

Em síntese, a capacidade de quantificar a experiência por meio do ES oferece um sinal objetivo que pode ser explorado por mantenedores de projetos OSS e plataformas de colaboração, tanto para fins de reconhecimento de contribuições quanto para a melhoria de processos de triagem e revisão de código.

Como continuidade deste trabalho, propõe-se expandir o escopo da pesquisa para outras plataformas além do GitHub, incorporar métricas sociais e qualitativas que capturem interações entre desenvolvedores e aprimorar o *Experience Score* com novas dimensões que reflitam melhor os aspectos técnicos e sociais da experiência dos contribuidores.

Referências

- Bosu, A. and Carver, J. C. (2013). Impact of peer code review on peer impression formation: A survey. In *2013 ACM/IEEE International Symposium on Empirical Software Engineering and Measurement*, pages 133–142, Baltimore, MD, USA.
- Creswell, J. W. (2010). *Projeto de pesquisa: métodos qualitativo, quantitativo e misto*. Bookman, Porto Alegre, 3 edition.
- Dey, T., Karnauch, A., and Mockus, A. (2020). Representation of developer expertise in open source software. In *ACM Conference*, page 11.
- Dey, T. and Mockus, A. (2020). Effect of technical and social factors on pull request quality for the npm ecosystem. *arXiv preprint arXiv:2007.04816*.
- Lima, A., Rossi, L., and Musolesi, M. (2014). Coding together at scale: Github as a collaborative social network. In *Proceedings of the [Conference Name]*, Birmingham, UK (Instituição de afiliação dos autores). Association for the Advancement of Artificial Intelligence. Copyright ©2014, Association for the Advancement of Artificial Intelligence (www.aaai.org). All rights reserved. [2].
- Lin, B., Robles, G., and Serebrenik, A. (2017). Developer turnover in global, industrial open source projects: Insights from applying survival analysis. In *IEEE 12th International Conference on Global Software Engineering*, pages 66–75.
- Mockus, A. and Herbsleb, J. D. (2002). Expertise browser: A quantitative approach to identifying expertise. In *International Conference on Software Engineering (ICSE)*, pages 503–512, Orlando, Florida.
- Montandon, J. E., Silva, L. L., and Valente, M. T. (2019). Identifying experts in software libraries and frameworks among github users. In *IEEE/ACM 16th International Conference on Mining Software Repositories (MSR)*, pages 276–287.

- Perez, Q., Urtado, C., and Vauttier, S. (2023). Dataset of open-source software developers labeled by their experience level in the project and their associated software metrics. *Data in Brief*, 46:108842.
- Rastogi, A., Nagappan, N., Gousios, G., and Hoek, A. v. d. (2018). Relationship between geographical location and evaluation of developer contributions in github. In *ACM / IEEE International Symposium on Empirical Software Engineering and Measurement (ESEM)*, page 8, Oulu, Finland. ACM.
- Wazlawick, R. S. (2014). *Metodologia de pesquisa para ciência da computação*. Elsevier, Rio de Janeiro, 2 edition.
- Zhang, Y., Qin, M., Stol, K.-J., Zhou, M., and Liu, H. (2024). How are paid and volunteer open source developers different? a study of the rust project. In *2024 IEEE/ACM 46th International Conference on Software Engineering (ICSE '24)*, page 13.